


골격 유사성과 역가를 직교화한 PDE5A 도킹 재평가

선행 상관의 재현 실패, 그리고 자세 타당도가 정하는 해석의 상한

smina / AutoDock Vina 1.1.2 · PDB 1UDT · ChEMBL PDE5A n = 163

전 산출물·코드·리뷰 기록 공개 — github.com/fourmodern/2026_aidrugdiscovery

홀로 구조를 쓰면 점수와 골격 닮음이 같은 방향을 가리킨다



사전에 정한 합격선은 넷이었다

목적	판정 지표	사전 합격선
1 역가를 정량 예측하는가	교차검증 Q^2	$Q^2 \geq 0.3$
2 강한 화합물을 선별하는가	순위상관 · ROC-AUC	$p < 0.05$ & $AUC \geq 0.7$
3 골격 통제 후에도 남는가	Tanimoto 편상관	원상관의 60% 이상 유지
4 대조 실패 시 무엇이 병목인가	C1 / C2 분리 + 통제 실험	후보를 실험으로 제거

사후성 고지 — 이 기준은 문헌 관행에서 가져왔고 데이터를 본 뒤 명문화했다 (논문 §2.6)

결론부터 — 넷 중 하나도 넘지 못했다

$\rho = -0.079$ (95% CI $-0.23 \sim +0.08$, $p = 0.31878$)

-0.018

교차검증 Q^2

기준 0.3 → 미달

0.574

ROC-AUC 전체

기준 0.7 → 미달

0.31878

순열 검정 p


기준 0.05 → 미달

“신호 없음”은 귀무를 채택한 것이 아니다

신뢰구간 상한이 $+0.08$ 이므로 $|\rho| \leq 0.23$ 인 관계는 이 데이터로 배제하지 못한다. 기각하지 못한 것이지 없다고 보인 것이 아니다.

역가와 골격 유사도를 9칸 격자로 직교화했다

Dataset: potency and scaffold similarity varied independently




ChEMBL PDE5A 활성 2538 레코드 전수 → 화합물당 중앙값 (2158종) → 9칸 격자 균등 추출 n = 163

교란 상관 Pearson +0.175 (역가만으로 증화한 옛 설계 +0.281)

재도킹 대조를 쫓개니 채점이 실패했다 — 163개 중 81%가 같은 실패다

Re-docking control separates pose generation from scoring



B Two controls, two verdicts

C1 sampling 1.08 Å **PASS**
best RMSD across modes

C2 ranking 8.37 Å **FAIL**
RMSD of the score-top pose

Without splitting the control, a single failing number would have been read as "docking does not work".

C1 샘플링 1.08 Å PASS

C2 채점 8.37 Å FAIL

그리고 이건 n=1 이 아니다


163개 전체 1위 자세의 MCS-RMSD 중앙값 4.50 Å, 2 Å 기준 통과 19.0%

→ 뒤에 나오는 상관은 대부분 틀린 자세에 매긴 점수에 대한 것이다

공결정 리간드 재도킹의 C2 실패는 예외가 아니라 전체의 축소판이다 — 같은 기준, 같은 실패, 163배 규모

탐색을 32배 늘려도 채점은 미동도 없었다

The bottleneck is scoring, not sampling: a search-depth experiment



C1 통과율 0% → 100%

C2 전 구간 0%, 변동 0.025 Å

최고 점수 변동 0.0 kcal/mol

프로토네이션도 원인이 아니었다 — 그리고 그럴 수 없었다


조건	C1 (Å)	C2 (Å)	점수	C2 통과
수용체 pH7.4 · 리간드 pH7.4 (옳은 짝)	1.10	8.37	-9.60	0%
수용체 pH7.4 · 리간드 중성 (현행)	1.07	8.36	-9.60	0%
수용체 중성 · 리간드 중성	1.22	8.37	-9.60	0%
수용체 중성 · 리간드 pH7.4	1.22	8.37	-9.60	0%

기본 Vina 채점 함수에는 정전기 항이 없다.

형식전하는 점수에 닿지 못하고, 바뀐 수소결합 타이핑도 그 질소가 결합 거리 밖이라 항 값이 움직이지 않았다. 원리적으로 원인이 될 수 없다.

여기까지가 자세 갈래 — C2 실패의 두 후보를 지웠다. 이제 상관 갈래로 넘어간다.

교란을 통제해도, 대역을 나눠도 신호는 없다



전체 **-0.079** 골격 통제 **-0.105** 골격+크기 **-0.088**

한 대역만 유의하지만, 그 신호는 칸 하나에 얹혀 있다

-0.397

near 대역 p ($p = 0.00365$)

0.792

AUC 95% CI [0.64, 0.95]

-0.219

전수 칸 제외 시 p

이 결과에 무게를 실을 수 없다

(a) AUC 신뢰구간이 사전 기준 0.7 을 포함한다 (b) 전수(census)인 약함 칸을 빼면 유의하지 않다 (c) 그 칸의 역가가 어세이 바닥값에 몰려 있다

그리고 대역별 자세 타당도가 해석을 다시 제한한다

far 1.8% · mid 31.4% · near 25.0% 만 2 Å 기준 안에 있다

이 지표는 “자세가 맞는가” 가 아니라 “공유 부분구조가 공결정 리간드 위에 겹치는가” 를 잴다. 골격이 다른 far 대역에서는 해석이 특히 약하다.

다른 질문 — $n=30$ 의 -0.538 은 어디서 왔나 (우리 초안의 답도 틀렸다)

① 옛 데이터에 골격 통제	$-0.538 \rightarrow -0.532$	감쇠 1.2%
② 옛 데이터의 점수 vs Tanimoto	-0.131	$p = 0.48923$
③ 옛 설계를 새 데이터에 재현	중앙값 -0.148	-0.4 미만 4.7%
④ 옛 30건을 새 프로토콜로 재도킹	$-0.538 \rightarrow -0.527$	점수 상관 $+0.997$

이 판본의 초안은 “골격 교란 때문” 이라고 적었다. 검토해 보니 1.2% 였다.

네 검토가 모두 후보를 배제한다. 원인은 그 화합물 집합 자체이며, 어떤 성질 때문인지는 이 데이터로 더 좁히지 못했다 — 그렇게 적었다.

무엇을 말할 수 있고, 무엇이 남았나

실험으로 제거한 것

C2 자세순위 실패의 원인 2개

탐색 깊이 · 프로토네이션

n=30 비재현의 설명 2개

골격 교란 · 프로토콜 차이

아직 배제하지 못한 것

물 전량 제거 · 강제 수용체

단일 배좌 · holo 유도적합 편향

그리고 채점 함수 자체

이들은 검정하지 않았다

두 갈래는 서로 다른 현상이다 — 하나로 세지 않는다

가져가실 것 셋

- ① 재도킹 대조를 C1/C2 로 쪼개고 깊이를 흔들어 병목을 특정하라
- ② 점수를 매긴 자세가 어디에 놓였는지 먼저 보고하라 — 이 연구에서는 19% 였다
- ③ 벤치마크의 골격 분포를 통제하라 (다만 여기서 그 통제가 바꾼 몫은 거의 0 이었다)

같은 데이터로 세 판본, 세 결론. 매번 게이트는 전부 통과했다.

방금 보신 11번 슬라이드가 그 세 번째입니다 — 이 판본의 초안도 틀렸고, 그걸 잡은 것은 자동 검증이 아니라 외부 비평이었습니다.

게이트는 수치가 산출되었는지를 검사할 뿐, 결론이 데이터에서 따라 나오는지 검사하지 못한다.

세 판본의 차이와 리뷰 기록 전부 공개

github.com/fourmodern/2026_aidrugdiscovery → Day06_LLM_Agent/pde5_harness