


검증 게이트를 갖춘 신약탐색 에이전트 하네스의 단일 실행 기록

그리고 그 게이트 중 둘이 반증 불가능했다는 발견

Can an agent harness keep a drug-discovery pipeline honest?

PDE5A inhibitor triage under file-encoded contracts and executable gates



Every result value in this report is a tool return value

UniProt O76074 lookup · ChEMBL CHEMBL1827 actives · RDKit descriptors

Prose is human-written; environment strings are captured by script. Unavailable quantities are reported as unavailable.


하네스 구조

계약 · 도구 · 봉투 · 게이트

Harness architecture: contract, tools, envelope, gate

CLAUDE.md — workflow order · per-step pass conditions · no-fabrication rules

.claude/skills/*/SKILL.md (when to call, how to call, what to verify) · .claude/settings.json (PostToolUse hooks)





every tool returns the same envelope { result , provenance , verification }

verification.passed = false blocks the next step in 3 of 4 steps — the 4th discarded the return value


물성 공간

게이트 결과로 색을 나눈 실제산값



단계별 잔존


앞의 두 조건은 아무것도 탈락시키지 않았다



QED 임계


임계 하나가 통과와 탈락을 갈랐다

Every compound ranked by QED — the threshold is the whole decision



임계 민감도

측정값은 그대로, 임계만 옮겨 재집계



화합물 물성 실계산값

검사 대상	실행 시점 강제	근거
target-lookup 게이트	차단함	if env is None or not gate(...): return 1
chembl-actives 게이트	차단함	동일
mol-properties 게이트	차단함	동일. 단 약물성 판정(gate_pass)은 verification.passed 에 포함되지 않아 10건 전부 탈락해도 이 단계는 통과한다
selectivity 게이트	차단하지 않았음	반환값을 버림 (if env is not None: gate(...))
selectivity 검사 항목	반증 불가능했음	4개 항목이 전부 모듈 리터럴 상수를 읽음. 쓰레기 SMILES 입력으로도 passed=True
report 게이트 (numbers_backed)	실행되지 않음	실행 코드에 호출자 0곳

QED 내림차순 상위 6건. 값은 전부 RDKit 산출값이며 사람이 적은 수치가 없다.

한계

1. 대조군이 없다.
문서-전용 조건을 실행하지 않았으므로 '문서보다 코드가 낫다'는 비교 주장은 하지 않는다.
2. 수정 후에도 selectivity 검사 5개가 이 실행에서는 공허하게 통과한다.
파이프라인이 SMILES 를 넘기지 않아 입력 의존 검사가 발동하지 않는다.
3. 단일 실행이며 반복이 없다. 통계 추론을 하지 않았다.
4. 화합물 10건은 정렬 미지정 조회의 앞부분이고 단일 화학형 계열에 가깝다.

게이트 통과는 규약 준수를 뜻할 뿐 화합물이 유망하다는 뜻이 아니다.

결론

1. 통과만 본 게이트는 검증된 것이 아니다.
단, 호출자가 반환값을 검사할 때만이다. 본 실행에서는 4단계 중 3단계만 그랬다.
2. 강제되었다고 기준이 옳은 것은 아니다.
이번 실행에서 통과·탈락을 가른 것은 QED 임계 0.5 하나였다.
3. 임계값은 근거와 함께 명시적으로 정해야 한다.
스크립트가 스스로 '데모 임계(교육용)'라고 밝힌 값이다.

본 보고의 결과 수치는 도구 산출값이다. 서술문과 절 제목은 사람이 작성했다.